

# T.C.

# ÜSKÜDAR ÜNİVERSİTESİ MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ ADLİ BİLİMLER BÖLÜMÜ

# **ABL440**

Adli Bilimlerde Büyük Veri

# FİNAL ÖDEVİ

Hazırlayan

Aysu İĞDİ

200207016

Doç.Dr. Kaan YILANCIOĞLU

# İÇİNDEKİLER

Takibi Yapılan Kitabın Künyesi	3
Uygulama	3
Veri Keşfi ve Görselleştirme (Data Exploration and Visualization)	4
Veri setinin boyutunu öğrenme: dim()	4
Veri setindeki değişken adlarını öğrenme: names()	4
Veri setinin yapısını ve niteliklerini öğrenme: str() ve attributes()	4
Verinin minimum, maksimum, ortalama, medyan, birinci ve üçüncü çeyrek değerlerini içe özeti inceleme: summary()	
Verinin çeyreklerini inceleme: quantile()	5
Verinin varyansını inceme: var()	5
Verinin histogram grafiği: hist()	5
Verinin pie chartı: pie(table())	6
Verinin kovaryans ve korelasyon: cov() ve cor()	6
Verinin düzgün dağılım grafiği (renk yoğunluğu): smoothScatter()	6
Verinin üç boyutlu dağılım grafiği: scatterplot3d()	6
Verinin ısı haritası: heatmap()	6
Decision Tree: train data	6
Decision Tree: test data	7
Random Forest	7
Random Forest: test data	8
Regresyon	8
Kümeleme (Clustring)	10
Aykırı Değer Tespiti (Outlier Detection)	
Time Series Data in R	11
Time Series Forecasting	11

# Takibi Yapılan Kitabın Künyesi

Kitap Adı : R and Data Mining -- Examples and Case Studies

Yazar : Yanchang Zhao

Yayınevi : Academic Press, Elsevier

Yayım Tarihi : Aralık 2012

ISBN : 978-0-123-96963-7

# **Uygulama**

GitHub : <u>igdiaysu/big-data-in-fs</u>

Konsoldan çalışma alanı ayarlandı.

> setwd("D:/GitRepository/big-data-in-fs/final")

\_\_\_

İlk bulunan dataset: AIDS Deaths by State

Source: NCHHSTP AtlasPlus Portal

Ayarlanan datasetin özellikleri:

• Gösterge (indicator) : HIV ölümleri

• Coğrafya : Bölge (region)

Midwest

West

o South

• Yıl : 2008-2019

 Veriler 2008-2021 arası olsa da sitede pandemi sebepli verilerle ilgili uyarı bulunmasından ötürü 2019 olarak daralttım.

• Yaş : 13+

Irk/Etnik Köken : Beyaz Cinsiyet : Kadın

• Bulaşma Kategorisi : Tüm kategoriler

o Enjeksiyonla uyuşturucu alımı

Heteroseksüel ilişki

o Diğer







```
> library(readr)
> HIV_deaths2 <-
read_csv("D:/GitRepository/big-data-in-fs/final/HIV_deaths2.cs
v")</pre>
```

## Veri Keşfi ve Görselleştirme (Data Exploration and Visualization)

```
Veri setinin boyutunu öğrenme: dim()
```

```
> dim(HIV_deaths2)
[1] 36 6
```

# Veri setindeki değişken adlarını öğrenme: names ()

```
> names(HIV_deaths2)
[1] "Indicator" "Year" "Geography" "FIPS" "Cases" "Rate per 100000"
```

# Veri setinin yapısını ve niteliklerini öğrenme: str() ve attributes()

```
> str(HIV_deaths2)
spc_tbl_[36 \times 6] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
                   : chr [1:36] "HIV deaths" "HIV deaths" "HIV deaths" "HIV deaths" ...
$ Indicator
                   : num [1:36] 2008 2009 2010 2011 2012 ...
: chr [1:36] "Midwest" "Midwest" "Midwest" ...
$ Geography
$ FIPS
                   : num [1:36] 83002 83002 83002 83002 83002 ...
 $ Cases
                   : num [1:36] 114 98 114 106 123 93 83 83 115 124 ...
 $ Rate per 100000: num [1:36] 0.5 0.4 0.5 0.5 0.5 0.4 0.4 0.4 0.5 0.5 ...
 - attr(*, "spec")=
  .. cols(
       Indicator = col_character(),
       Year = col_double(),
  . .
       Geography = col_character(),
  . .
       FIPS = col_double(),
       Cases = col_double(),
  . .
        Rate per 100000` = col_double()
 - attr(*, "problems")=<externalptr>
```

```
attributes(HIV_deaths2)
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36
$names
[1] "Indicator"
                                                            "FIPS"
                       "Year"
                                          "Geography"
                                                                               "Cases"
                                                                                                  "Rate per 100000"
 Indicator = col_character(),
 Year = col_double(),
Geography = col_character(),
 FIPS = col_double(),
  Cases = col_double(),
  Rate per 100000` = col_double()
$problems
<pointer: 0x000002bc23a29cf0>
$class
[1] "spec_tbl_df" "tbl_df"
                                 "tb1"
                                                "data.frame"
```

# Verinin minimum, maksimum, ortalama, medyan, birinci ve üçüncü çeyrek

#### değerlerini içeren özeti inceleme: summary ()

```
> summary(HIV_deaths2)
 Indicator
                         Year
                                    Geography
                                                           FIPS
                                                                          Cases
                                                                                       Rate per 100000
Length:36
                    Min.
                           :2008
                                   Length:36
                                                      Min.
                                                             :83002
                                                                       Min.
                                                                             : 83.0
                                                                                       Min.
                                                                                             :0.4
Class :character
                    1st Ou.:2011
                                                      1st Ou.:83002
                                   Class :character
                                                                       1st Ou.:113.8
                                                                                       1st Ou.:0.5
                                                      Median :83003
Mode :character
                    Median :2014
                                   Mode :character
                                                                       Median :126.5
                                                                                       Median:0.7
                    Mean
                           :2014
                                                      Mean :83003
                                                                       Mean
                                                                             :199.6
                                                                                       Mean
                                                                                             :0.8
                    3rd Qu.:2016
                                                       3rd Qu.:83004
                                                                       3rd Qu.:345.2
                                                                                       3rd Qu.:1.1
                    Max.
                           :2019
                                                      Max.
                                                              :83004
                                                                       Max.
                                                                              :414.0
                                                                                       Max.
```

#### Verinin çeyreklerini inceleme: quantile ()

```
> quantile(HIV_deaths2$Cases)
    0% 25% 50% 75% 100%
83.00 113.75 126.50 345.25 414.00
> quantile(HIV_deaths2$`Rate per 100000`)
    0% 25% 50% 75% 100%
    0.4 0.5 0.7 1.1 1.3
```

#### Verinin varyansını inceme: var ()

100 bin kişi başına ölüm oranındaki sapmanın sonucu:

```
> var(HIV_deaths2$`Rate per 100000`)
[1] 0.09885714
```

#### Verinin histogram grafiği: hist()

200-300 arasında vaka bulunan bölge olmadığını görüyoruz.

```
Cases


100 200 300 400

YII
```

```
> hist(
+ HIV_deaths2$Cases,
+ main = "Cases",
+ xlab = "Y11",
+ ylab = "Frekans",
+ col = "lightblue",
+ )
```

# Verinin pie chartı: pie (table ())

> pie(table(HIV\_deaths2\$Geography))



## Verinin kovaryans ve korelasyon: cov () ve


## cor()

```
> cov(HIV_deaths2$Cases, HIV_deaths2$`Rate per 100000`)
[1] 36.04
> cor(HIV_deaths2$Cases, HIV_deaths2$`Rate per 100000`)
[1] 0.9409925
```


## Verinin düzgün dağılım grafiği (renk yoğunluğu):

#### smoothScatter()

> smoothScatter(HIV\_deaths2\$Cases, HIV\_deaths2\$`Rate per 100000`)



# Verinin üç boyutlu dağılım grafiği: scatterplot3d()



# Verinin ısı haritası: heatmap ()

Isı haritası kullanımını gerektiren sayıda veri satırı bulunmamaktadır.

#### **Decision Tree: train data**

Başlangıçta `Geography`nin değişkenin türü değiştirildi: chracter → factor
Tekrarlanabilirlik için seed girdisi yapıldı. Aynı sürümde farklı bilgisayarda bile aynı sonuçların tekrar edilebilmesi için (Aynı rastgelelik).

```
# HIV_deaths2$Geography<-as.factor(HIV_deaths2$Geography)
set.seed(444)
ind <- sample(2, nrow(HIV_deaths2), replace=TRUE, prob=c(0.7, 0.3))
trainData <- HIV_deaths2[ind==1,]
testData <- HIV_deaths2[ind==2,]
library(party)
myFormula <- Geography ~ Year + Cases + `Rate per 100000`
hiv_ctree <- ctree(myFormula, data=trainData)

# check the prediction >
table(predict(hiv_ctree), trainData$Geography)
```

#### table(predict(hiv\_ctree), trainData\$Geography)

```
\begin{array}{ccccc} & \text{Midwest South West} \\ \text{Midwest} & 10 & 0 & 0 \\ \text{South} & 0 & 9 & 0 \\ \text{West} & 1 & 0 & 9 \end{array}
```

#### > print(hiv\_ctree)

Response: Geography

Conditional inference tree with 3 terminal nodes

Inputs: Year, Cases, Rate per 100000


Number of observations: 29

1) Cases <= 167; criterion = 1, statistic = 27.393
2) Rate per 100000 <= 0.5; criterion = 1, statistic = 14.394
3)\* weights = 10
2) Rate per 100000 > 0.5

4)\* weights = 10

1) Cases > 167
5)\* weights = 9

plot(hiv\_ctree, type="simple")



#### **Decision Tree: test data**

Tamamını doğru tahmin etti.

#### **Random Forest**

#### trainData işlemleri:

```
HIV_deaths3$Geography<-as.factor(HIV_deaths3$Geography)
ind <- sample(2, nrow(HIV_deaths3), replace=TRUE, prob=c(0.7, 0.3))
trainData <- HIV_deaths3[ind==1,]
testData <- HIV_deaths3[ind==2,]
library(randomForest)
rf <- randomForest(Geography ~ Year + Cases + `Rate`, data=trainData, ntree=100, proximity=TRUE)
table(predict(rf), trainData$Geography)</pre>
    Midwest South West
                                   9
0
0
                                                            1
0
7
     South
West
 > print(rf)
Call:
randomForest(formula = Geography ~ Year + Cases + Rate, data = trainData,
Type of random forest: classification
Number of trees: 100
No. of variables tried at each split: 1
                                                                                                                                                                      ntree = 100, proximity = TRUE)
                 OOB estimate of error rate: 3.85%
OB estimate of error rate: 3.

Confusion matrix:

Midwest South West class.error

Midwest 9 0 0 0.000

South 0 9 0 0.000

West 1 0 7 0.125
   attributes(rf)
> attributes (1)


$names


[1] "call"

[7] "oob.times"

[13] "ntree"

[19] "terms"
                                                                                       "nredicted"
                                                                                                                            "err rate"
                                                                                                                                                                  "confusion"
                                                                                                                                                                                                        "votes"
                                                                                      "importance"
"forest"
                                                                                                                                                                 "localImportance" "proximity"
"test" "inbag"
                                                                                                                            "importanceSD"
 $class
[1] "randomForest.formula" "randomForest"
```





100 ağaç üretilerek çalıştırılmış modelde 60'tan sonra değişiklik olmadığı gözlemlenerek 60 ağaçla tekralanıp grafik gözlemlendi.

```
> importance(rf)
MeanDecreaseGini
Year 1.485198
Cases 6.243888
Rate 8.856384
```

Tahmin etmede değişkenlerin önemine dair tablo.

#### Random Forest: test data

3 Mindwest'ten 1 tanesini West olarak tahmin etti.


# Regresyon


Regresyon, bağımlı bir değişkeni (yanıt olarak da adlandırılır) tahmin etmek için bağımsız değişkenlerin (tahmin ediciler olarak da bilinir) bir fonksiyonunu oluşturmaktır.


```
y = c_0 + c_1 x_1 + c_2 x_2 + \dots + c_k x_k,  > \text{reg} <- \text{lm}(\text{HIV\_deaths3\$Rate} \sim \text{HIV\_deaths3\$Year} + \text{HIV\_deaths3\$Cases}) > \text{reg}   \text{Call:} \\ \text{lm}(\text{formula} = \text{HIV\_deaths3\$Rate} \sim \text{HIV\_deaths3\$Year} + \text{HIV\_deaths3\$Cases})   \text{Coefficients:} \\ \text{(Intercept)} \qquad \text{HIV\_deaths3\$Year} \quad \text{HIV\_deaths3\$Cases} \\ \text{3.31471} \qquad -0.00149 \qquad 0.00243
```


#### 


Residual standard error: 0.1095 on 33 degrees of freedom Multiple R-squared: 0.8857, Adjusted R-squared: 0.8788 F-statistic: 127.9 on 2 and 33 DF, p-value: 2.852e-16












> library(scatterplot3d)
> s3d <- scatterplot3d(HIV\_deaths3\$Rate, HIV\_deaths3
\$Year, HIV\_deaths3\$Cases, highlight.3d=T, type="h", lab=c(2,3))
> s3d\$plane3d(reg)



## **Kümeleme (Clustring)**

2 10 0

West

```
> hiv2 <- HIV_deaths3
> hiv2$Geography <- NULL
> hiv2$Indicator <- NULL</pre>
 > hiv2fFIPS <- NULL
> (kmeans.result <- kmeans(hiv2, 3))
K-means clustering with 3 clusters of sizes 8, 16, 12
 Cluster means:
Year Cases Rate
1 2013.375 95.2500 0.462500
2 2013.562 126.3750 0.675000
 3 2013.500 366.8333 1.191667
Within cluster sum of squares by cluster:

[1] 609.4337 2956.0175 7704.7358

(between_SS / total_SS = 97.8 %)
 Available components:
                          "centers"
"ifault"
 [1] "cluster'
[8] "iter"
                                              "totss"
                                                                 "withinss"
                                                                                     "tot.withinss" "betweenss"
                                                                                                                             "size"
12-12-12 bulamadı.
> table(HIV_deaths3$Geography, kmeans.result$cluster)
                 1
                           3
   Midwest
                 6
                      6
                          0
                     0 12
   South
                 0
```

West ve Midwest'in iki ayrı kümeye dağılması hepsini doğru kümeyemediğini gösteriyor. 3 = South. Ama 1 ve 2'yi bilemeyiz.

Verinin azlığı sebebiyle kmeans'tan verim alınamadığından diğer metotlar eklenmemiştir.

## Aykırı Değer Tespiti (Outlier Detection)


```
> boxplot.stats(HIV_deaths3$Rate)$out
numeric(0)
> boxplot(HIV_deaths3$Rate)


> attach(df)
The following object is masked from df (pos = 3):
    HIV_deaths3.Rate

The following object is masked from df (pos = 4):
    HIV_deaths3.Rate

> (a <- which(HIV_deaths3$Cases %in% boxplot.stats(HIV_deaths3$Cases)$out)) integer(0)
> detach(df)
> (b <- which(HIV_deaths3$Rate %in% boxplot.stats(HIV_deaths3$Rate)$out)) integer(0)
> (outlier.list1 <- intersect(a,b)) integer(0)</pre>
```

Verimde outlier çıkmadığı için bölümün kalanı veri setine uygulanmadı.






## Time Series Data in R

```
> # Time Series
> a <- ts(1:12, frequency=1, start=c(2008,1))
> a
Time Series:
Start = 2008
End = 2019
Frequency = 1
[1] 1 2 3 4 5 6 7 8 9 10 11 12
> |
```

# **Time Series Forecasting**

#### **Cases Over Time**



#### **Forecasted Cases Over Next 2 Year**

